

Proposal Proyek Data Warehouse

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-D
Ketua	Meisya Natasafira (24031554174)
Anggota 1	Nasliyatul Intani (24031554097)
Anggota 2	Aryanti Indah Lestari (24031554196)
URL Github	https://github.com/aryanti11/Analisis-Tren-Insiden-Kejahatan-di-Kota-Philadelphia-Amerika-Serikat-Tahun2023-2024-Berbasis-OLAP

Informasi Umum Proyek

Judul	<i>Analisis Tren Insiden Kejahatan di Kota Philadelphia Amerika Serikat pada Tahun 2023-2024 Menggunakan Dataset Crime Incident Berbasis OLAP</i>
Topik	<i>Sosial</i>
Revisi?	<i>Ya / Tidak</i>

Deskripsi Rumusan masalah	Kriminalitas merupakan salah satu permasalahan sosial yang penting untuk dianalisis karena dapat mempengaruhi tingkat keamanan suatu wilayah. Dataset Crime Incidents Kota Philadelphia menyediakan informasi mengenai jenis kejahatan, lokasi, dan waktu kejadian yang dapat digunakan untuk melihat pola kriminalitas selama tahun 2023-2024. Permasalahan dalam project ini adalah bagaimana melakukan analisis tren kejahatan secara efektif menggunakan pendekatan Data warehouse dan OLAP. Permasalahan ini belum terselesaikan secara optimal karena data kriminal memiliki volume besar, terdiri dari banyak atribut, serta tersebar dalam berbagai dimensi seperti waktu, lokasi, dan jenis kejahatan sehingga sulit dianalisis secara cepat. Tantangan utama dalam penyelesaian masalah ini adalah proses integrasi data, pengolahan data dalam jumlah besar, serta kebutuhan analisis multidimensi yang terstruktur. Oleh karena itu, pada project ini akan dibangun Data Warehouse dan OLAP cube untuk membantu proses analisis data kriminal secara lebih cepat, terstruktur, dan interaktif melalui mekanisme slice, dice, drill-down, dan roll-up.
Target insight yang ingin dicapai	1. Mengetahui jenis kejahatan yang paling sering terjadi pada tahun 2023-2024. 2. Menganalisis tren peningkatan atau penurunan jumlah kejahatan berdasarkan periode waktu. 3. Mengidentifikasi wilayah atau distrik dengan tingkat kriminalitas tertinggi di Kota Philadelphia. 4. Mengetahui pola kejahatan berdasarkan waktu kejadian, seperti jam, hari, dan bulan tertentu. 5. Membantu proses pengambilan keputusan melalui visualisasi data dan analisis OLAP berbasis Data Warehouse.
Referensi penelitian	1. https://doi.org/10.30534/ijatcse/2020/313952020 2. https://doi.org/10.1080/01621459.2022.2156348 3. https://doi.org/10.1007/s11292-019-09400-2 4. https://doi.org/10.1089/big.2020.0045 5. https://doi.org/10.1016/j.procs.2020.09.337

Informasi Detail Dataset

Sumber dataset	<i>Dataset diperoleh dari portal resmi pemerintah Amerika Serikat melalui url berikut: https://catalog.data.gov/dataset/crime-incidents Proses akuisisi data dilakukan dengan mengunduh dataset Crime Incidents yang tersedia dalam format CSV pada portal tersebut. Dataset kemudian akan diproses melalui tahapan extract, transform, load (ETL), sebelum dimasukkan ke dalam Data Warehouse</i>
Deskripsi umum dataset / data dump	<i>Dataset Crime Incidents berasal dari Departemen Kepolisian Philadelphia yang berisi laporan insiden kejahatan di Kota Philadelphia. Dataset ini mencakup informasi mengenai jenis kejahatan, waktu kejadian, dan lokasi kejadian. Kejahatan Bagian I meliputi tindak kriminal berat seperti aggravated assault, pemerkosaan, pembakaran, dan tindak kekerasan lainnya. Sedangkan kejahatan bagian II mencakup pelanggaran non-kekerasan seperti penyerangan ringan, prostitusi, perjudian, penipuan, dan pelanggaran lainnya. Dataset ini memiliki berbagai atribut penting seperti tanggal kejadian, distrik lokasi, kategori pelanggaran, serta informasi wilayah administratif.</i>
Aspek khusus dari dataset	<i>Dataset Crime Incidents memiliki karakteristik data yang cukup kompleks untuk dianalisis. Dataset ini memiliki volume data yang besar dengan atribut yang beragam. Sebagian besar data bersifat terstruktur, namun terdapat kemungkinan adanya missing value pada beberapa atribut tertentu seperti koordinat lokasi atau detail tambahan lainnya. Selain itu, distribusi data cenderung tidak seimbang (imbalanced) karena beberapa jenis kejahatan memiliki jumlah kasus yang jauh lebih tinggi dibanding kategori kejahatan lainnya. Dataset ini juga berpotensi memiliki outlier, misalnya lonjakan jumlah kriminalitas pada waktu atau wilayah tertentu. Sebaran data yang terdiri dari dimensi waktu, lokasi, dan jenis kejahatan membuat dataset ini sesuai untuk analisis multidimensi menggunakan OLAP cube.</i>

Rencana Data Staging

Gambaran umum proses ekstraksi	<i>Tahapan ekstraksi dilakukan dengan mengambil dataset Crime Incident dari portal resmi pemerintah Amerika Serikat melalui situs Data.gov- Crime Incidents Dataset. Dataset yang digunakan difokuskan pada data insiden kriminal di Kota Philadelphia tahun 2023-2024. Proses ekstraksi dilakukan dengan cara mengunduh dataset dalam format CSV, kemudian data dipindahkan ke area staging sebagai tempat penyimpanan sebelum diproses lebih lanjut. Pada tahap ini data masih berupa data mentah dan belum mengalami perubahan struktur. Tahapan ekstraksi meliputi : mengunduh dataset, memilih data dengan rentang waktu tahun 2023-2024, menyimpan data mentah ke dalam database staging, melakukan pengecekan awal terhadap struktur data, tipe atribut, jumlah record, dan kelengkapan data, serta menyiapkan data untuk proses transformasi dan integrasi ke data warehouse.</i>
Gambaran umum proses transformasi	<i>Tahap transformasi dilakukan untuk membersihkan dan menyesuaikan data agar siap digunakan dalam data warehouse dan analisis OLAP. Dataset kriminalitas memiliki kemungkinan adanya data kosong, inkonsistensi format, serta atribut yang belum sesuai dengan struktur Data Warehouse. Beberapa proses transformasi yang direncanakan adalah sebagai berikut :</i> <i>1. Pembersihan missing value, atribut yang memiliki nilai kosong seperti koordinat geografis, lokasi, atau status kasus akan ditangani menggunakan proses data cleaning. Data penting yang kosong dapat dihapus atau diisi dengan nilai default tertentu sesuai kebutuhan analisis.</i> <i>2. Standarisasi format data, format tanggal, waktu, nama distrik, serta kategori kriminalitas akan diseragamkan.</i> <i>3. Transformasi dimensi waktu, atribut tanggal akan dipecah menjadi beberapa atribut tambahan seperti tahun, bulan, hari dan lainnya.</i>

	4. Kategorisasi dan pengelompokan data, jenis kriminalitas akan dikelompokkan ke dalam kategori tertentu. 5. Validasi dan penghapusan duplikasi, data yang memiliki record ganda akan diidentifikasi dan
Gambaran umum Proses load	Tahap load merupakan proses memasukkan data yang telah melalui tahap transformasi ke dalam Data Warehouse. Data akan disimpan ke dalam tabel fakta dan tabel dimensi menggunakan skema bintang (star schema) untuk mendukung analisis OLAP. Struktur Data Warehouse yang direncanakan menggunakan skema bintang (star schema) dengan komponen utama tabel fakta dan tabel dimensi. Workflow penyimpanan data ke dalam Data Warehouse direncanakan sebagai berikut: 1. Data Source , dataset kriminalitas diambil dari portal Data.gov dalam format CSV. 2. Staging Area , Data mentah disimpan sementara pada area staging untuk proses ETL . 3. Data Cleaning dan Transformation, dilakukan proses handling missing value, standarisasi, validasi, dan pembentukan atribut dimensi. 4. Pembentukan Star Schema, data dipisahkan ke dalam tabel fakta dan tabel dimensi sesuai kebutuhan OLAP. 5. Loading ke Data Warehouse, data hasil transformasi dimasukkan ke database Data Warehouse. 6. Pembuatan OLAP Cube, Data warehouse digunakan untuk membangun cube OLAP agar mendukung analisis multidimensi berdasarkan: waktu, lokasi, jenis kriminalitas, dan status kasus. 7. Analisis dan Visualisasi, data kemudian digunakan untuk membuat dashboard, laporan tren kriminalitas, dan analisis interaktif berbasis OLAP.

Rencana Data Presentation

Subject focus	Subject utama yang diangkat dalam proses OLAP adalah analisis insiden kejahatan di Kota Philadelphia selama tahun 2023–2024 dengan fokus pada identifikasi pola kriminalitas berdasarkan dimensi waktu, lokasi, dan jenis kejahatan. Melalui pendekatan OLAP, analisis multidimensi dapat dilakukan untuk mengetahui tren jumlah kejahatan berdasarkan periode waktu, distribusi kejahatan pada berbagai wilayah, jenis kejahatan yang paling dominan, pola kejadian berdasarkan jam, hari, atau bulan tertentu, serta perbandingan tingkat kriminalitas antar wilayah. Subject ini dipilih karena data kriminal memiliki karakteristik multidimensi yang sesuai untuk implementasi Data Warehouse dan OLAP, sehingga proses analisis dapat dilakukan secara lebih cepat, terstruktur, fleksibel, dan interaktif guna mendukung pengambilan keputusan.
Star schema	Terdiri dari satu tabel fakta dan beberapa tabel dimensi:

	<pre> graph TD DimCrime[Dim_Crime] --- FactCrimeIncident[Fact_Crime_Incident] DimTime[Dim_Time] --- FactCrimeIncident DimLocation[Dim_Location] --- FactCrimeIncident DimDistrict[Dim_District] --- FactCrimeIncident </pre> <i>Penjelasan:</i> 1. <i>Fact_Crime_Incident (Fact Table):</i> Tabel ini merupakan tabel fakta yang menjadi pusat dalam proses OLAP karena menyimpan data numerik utama yang akan dianalisis. Measure: total_incident 2. <i>Dim_Time:</i> Tabel ini berfungsi sebagai dimensi waktu untuk mendukung analisis temporal. Hierarchy: Year → Month → Day (dispatch_date) → Hour 3. <i>Dim_Crime:</i> Tabel ini menyimpan informasi mengenai jenis kejahatan. Hierarchy: UCR General Category → Crime Description 4. <i>Dim_Location:</i> Tabel ini menyimpan informasi lokasi kejadian kriminal. Hierarchy: Coordinate → Location Block 5. <i>Dim_District:</i> Tabel ini menyimpan informasi administratif wilayah kepolisian. Hierarchy: District → PSA
Target hasil OLAP	<i>Insight yang ingin dicapai melalui mekanisme OLAP dalam proyek ini meliputi:</i> 1. <i>Identifikasi jenis kejahatan dominan:</i> Mengetahui jenis kejahatan yang paling sering terjadi di Kota Philadelphia selama periode 2023–2024. 2. <i>Analisis tren kriminalitas berdasarkan waktu:</i> Mengidentifikasi pola peningkatan atau penurunan jumlah insiden kejahatan berdasarkan tahun, kuartal, bulan, hari, maupun jam tertentu. 3. <i>Identifikasi wilayah dengan tingkat kriminalitas tertinggi:</i> Menentukan distrik atau wilayah dengan jumlah kejadian kriminal paling tinggi untuk mengetahui area rawan kejahatan. 4. <i>Analisis pola waktu kejadian kriminal:</i> Mengetahui waktu-waktu tertentu yang memiliki frekuensi kejahatan tinggi, seperti jam rawan, hari tertentu, atau periode bulanan tertentu. 5. <i>Perbandingan distribusi kriminalitas antar wilayah:</i> Membandingkan tingkat kriminalitas antar distrik atau neighborhood untuk melihat perbedaan pola kejahatan di setiap wilayah.